

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине: «Модели решения задач в интеллектуальных системах»
Тема: «Многослойный персептрон для задачи «исключающее ИЛИ» с числовыми классами: сравнение функций потерь MSE и Binary Cross-Entropy»

Выполнил:
Студент 4 курса
Группы ИИ-25
Ящук М.Ю.
Проверила:
Андренко К.В.

Цель работы: на основе многослойного персептрона архитектуры 2-2-1, реализованного в Лабораторной работе №1 для задачи XOR с числовыми классами c_0 и c_1 из диапазона $[-10; 10]$, реализовать альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провести сравнительный анализ обучения сети с MSE (Лабораторная работа №1) и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.

Задание:

- взять за основу код многослойного персептрона 2-2-1 из Лабораторной работы №1;
 - поскольку BCE определена для выходов в диапазоне $(0; 1)$, а целевые значения в вашем варианте – произвольные числа c_0 и c_1 из диапазона $[-10; 10]$, реализовать нормализацию (масштабирование) целевых значений перед обучением и обратное преобразование выхода сети после обучения:
 - привести c_0 и c_1 к бинарным меткам 0 и 1;
 - обучать сеть на нормализованных целевых значениях с функцией потерь BCE;
 - при выводе результата преобразовывать выход сети $\hat{y} \in (0; 1)$ обратно в шкалу $[c_0; c_1]$.
 - реализовать корректный градиент для связки BCE + сигмоида на выходном слое; для скрытого слоя градиент передаётся по стандартному правилу цепочки.
 - обучить сеть на полной таблице истинности своего варианта (4 примера) в двух конфигурациях:
 - **конфигурация А (базовая, из ЛР №1):** MLP 2-2-1, функция потерь MSE, целевые значения – исходные c_0/c_1 , выходной слой – сигмоида. Результаты можно взять из отчёта по ЛР №1 или, при необходимости, повторить обучение с фиксацией всех метрик.
 - **конфигурация Б (новая):** MLP 2-2-1, функция потерь BCE, целевые значения – нормализованные $(0/1)$, с последующим пересчётом выхода в шкалу $[c_0; c_1]$.
- Критерий остановки для обеих конфигураций одинаков – суммарная ошибка $E_s \leq E_e$ (используйте то же значение E_e , что и в ЛР №1, либо согласуйте новое значение отдельно для MSE и для BCE, поскольку это разные по своей природе величины – обсудите выбор в отчёте);
- для каждой конфигурации зафиксировать:
 - количество эпох до достижения критерия остановки (либо факт недостижения за максимально допустимое число эпох);
 - итоговую суммарную ошибку;
 - ассигнату на всех 4 примерах таблицы истинности;
 - среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.
 - провести не менее 5 запусков обучения для каждой конфигурации с разной случайной инициализацией весов (менять seed) и сравнить устойчивость сходимости: в скольких из 5 запусков сеть достигла критерия остановки, и какой разброс по числу эпох наблюдается;

- построить общий график зависимости суммарной ошибки от номера эпохи для конфигурации А (MSE) и конфигурации Б (BCE) на одних осях (для представительного запуска каждой конфигурации);
- реализовать блок визуализации результатов, включающий:
 - **график сходимости**– суммарная ошибка E_s от номера эпохи, конфигурации А и Б на одних осях, разными цветами/стилями линий, с обозначением порога E_e ;
 - **диаграмму разброса числа эпох по 5 запускам**(bar chart или scatter) для конфигурации А и конфигурации Б – наглядно показывающую устойчивость сходимости из п. 6 (например, столбики числа эпох для каждого из 5 seed, сгруппированные по конфигурации; запуски, не достигшие критерия остановки, отметить отдельно, например штриховкой или отдельным цветом);
 - **визуализацию разделяющей поверхности скрытого слоя** – для представительного обученного экземпляра каждой конфигурации построить на плоскости (А, В) карту выходного значения сети (heatmap или contour plot) с наложенными точками обучающей выборки (4 примера таблицы истинности), закрашенными по истинному классу. Диапазон осей А и В – $[-10; 10]$ (весь допустимый диапазон входных значений). Для конфигурации Б цветовую шкалу можно строить как по нормализованному $\hat{y} \in (0; 1)$, так и по пересчитанному значению в шкале $[c_0; c_1]$ – выбрать более наглядный вариант и обосновать выбор;
 - **диаграмму сравнения точности восстановления шкалы**– столбчатую диаграмму средней абсолютной ошибки для конфигурации А и конфигурации Б, чтобы наглядно сопоставить точность регрессии к исходной шкале $[c_0; c_1]$.

Каждый график должен иметь подписанные оси, заголовок и легенду (где применимо). Разделяющую поверхность и графики точности рекомендуется разместить рядом (например, subplot 2×2 или отдельными рисунками) для удобства сравнения в отчёте;

- реализовать режим функционирования сети: пользователь вводит пару чисел (А, В) из диапазона $[-10; 10]$ (не обязательно совпадающих с c_0 и c_1). Сеть должна выводить:
 - выход в нормализованной шкале $\hat{y} \in (0; 1)$ (с точностью до 4 знаков);
 - выход, пересчитанный в исходную шкалу $[c_0; c_1]$ по формуле из п. 2;
 - к какому классу (c_0 или c_1) ближе полученное значение.

Продемонстрировать работу режима функционирования на всех 4 примерах исходной таблицы истинности и не менее чем на 2–3 дополнительных парах (А, В), не входящих в обучающую выборку.

Вариант 14 ($c_0 = -5$, $c_1 = 10$)

А	В	$\begin{matrix} \text{А} \\ \oplus \text{В} \end{matrix}$
–	–	–
5	5	5
–	1	1
5	0	0
1	–	1
0	5	0
1	1	–
0	0	5

Изменения в архитектуре и алгоритме относительно ЛР1:

Архитектура сети (2-2-1, сигмоида на всех слоях) не менялась. Изменения – только в целевой функции и, дополнительно, во входной нормализации:

Нормализация целей (как и в ЛР1, поскольку сигмоида на выходе ограничена (0;1) и не может выдать -9 или 6):

$$y_{norm} = \frac{y - c_0}{c_1 - c_0}$$

Обратный пересчёт после обучения:

$$y = y_{norm} \cdot (c_1 - c_0) + c_0$$

Вывод градиента для связки ВСЕ + сигмоида (выходной слой):

Потери для одного примера:

$$L = -y \ln p - (1 - y) \ln(1 - p), \quad p = \sigma(z) = out$$

Цепное правило:

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial p} \cdot \frac{\partial p}{\partial z}$$

где

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p}, \quad \frac{\partial p}{\partial z} = p(1 - p)$$

Подставляем и сокращаем:

$$\frac{\partial L}{\partial z} = \left(-\frac{y}{p} + \frac{1 - y}{1 - p} \right) p(1 - p) = -y(1 - p) + (1 - y)p = p - y$$

Итог:

$$\delta_{out} = out - y$$

Градиент для скрытого слоя:

$$\delta_h = (\delta_{out} W_2^T) \odot h(1 - h)$$

Блок визуализации:

График сходимости:




Диаграмма числа эпох по 5 запускам:



Разделяющая поверхность:





Диаграмма MAE:



Вывод :

```
=== Таблица результатов ===
Loss Seed Эпохи Ошибка Accuracy MAE Сошлась
MSE 0 7286 0.001000 1.0000 0.3333 да
MSE 1 7698 0.001000 1.0000 0.3337 да
MSE 2 6935 0.001000 1.0000 0.3333 да
MSE 3 10000 0.250828 0.5000 3.8802 нет
MSE 4 7232 0.001000 1.0000 0.3332 да
BCE 0 761 0.049918 1.0000 0.1860 да
BCE 1 868 0.049906 1.0000 0.1859 да
BCE 2 691 0.049994 1.0000 0.1862 да
BCE 3 892 0.049889 1.0000 0.1858 да
BCE 4 736 0.049908 1.0000 0.1859 да

MSE: сходимость 4/5
Разброс эпох: 6935-7698

BCE: сходимость 5/5
Разброс эпох: 691-868

=== Проверочные примеры (конфигурация BCE) ===
A= -5.0, B= -5.0: y_norm=0.9997, y_real=-4.8546, класс=-5
A= -5.0, B= 10.0: y_norm=0.9888, y_real=9.8324, класс=10
A= 10.0, B= -5.0: y_norm=0.9889, y_real=9.8334, класс=10
A= 10.0, B= 10.0: y_norm=0.0177, y_real=-4.7347, класс=-5
A= 0.0, B= 0.0: y_norm=0.9774, y_real=9.6616, класс=10
A= -3.0, B= 7.0: y_norm=0.9901, y_real=9.8511, класс=10
A= 6.0, B= -2.0: y_norm=0.9902, y_real=9.8523, класс=10

Введите A и B через пробел (q для выхода): 3 5
Нормализованный выход: 0.9695
Выход в исходной шкале: 9.5432
Ближайший класс: 10

Введите A и B через пробел (q для выхода): -5 10
Нормализованный выход: 0.9888
Выход в исходной шкале: 9.8324
Ближайший класс: 10

Введите A и B через пробел (q для выхода): 0 10
Нормализованный выход: 0.9998
Выход в исходной шкале: 9.5119
Ближайший класс: 10

Введите A и B через пробел (q для выхода): -5 -5
Нормализованный выход: 0.9997
Выход в исходной шкале: -4.8546
Ближайший класс: -5

Введите A и B через пробел (q для выхода): 10 10
Нормализованный выход: 0.0177
Выход в исходной шкале: -4.7347
Ближайший класс: -5

Введите A и B через пробел (q для выхода): q
```

Вопросы:

1. **Какая функция потерь дала более быструю/устойчивую сходимость?** BCE – кардинально быстрее (691–868 эпох против 6935–7698 у MSE, т.е. примерно в 10 раз) и заметно устойчивее: сошлись все 5 запусков, тогда как у MSE один из пяти (seed=3) застрял в локальном минимуме ($E_s \approx 0.25$, accuracy 0.50, MAE 3.88) и не достиг порога за 10000 эпох. Это согласуется с теоретическим преимуществом BCE: градиент связки BCE+сигмоида равен просто $(out - y)$ и не гаснет при насыщении выхода, тогда как у MSE градиент содержит множитель $out(1 - out)$,

стремящийся к нулю при насыщении сигмоиды, – отсюда более медленное и менее надёжное обучение (эффект «исчезающего градиента»). Дополнительный фактор – разница порогов: $E_{e_MSE}=0.001$ для MSE и $E_{e_BCE}=0.05$ для BCE, поскольку это разные по природе величины.

2. **Как нормализация целей повлияла на обучение по сравнению с обучением на «сырых» числах $[-10;10]$?** Обучение напрямую на c_0/c_1 без нормализации с сигмойдой на выходе невозможно в принципе: сигмоида ограничена интервалом $(0;1)$ и никогда не выдаст -5 или 10 , поэтому суммарная ошибка застревает на уровне сотен и критерий E_e недостижим. Нормализация целей (приведение c_0/c_1 к $0/1$ по формуле $t=(y_{real}-c_0)/(c_1-c_0)$) – не опция, а обязательное условие корректной работы сигмоидного выхода. Дополнительно нормализация приводит входные и целевые значения к одному масштабу, что делает градиенты сопоставимыми по величине и ускоряет сходимость по сравнению с обучением на числах порядка десятков.
3. **Точность восстановления шкалы $[c_0;c_1]$: MSE vs BCE, есть ли компромисс?** MAE у BCE (0.186) меньше, чем у MSE (0.333), т.е. BCE выигрывает и по устойчивости классификации, и по точности регрессии к исходной шкале $[-5;10]$. Это объясняется тем, что BCE логарифмически штрафует «неуверенные» выходы и вынуждает сеть выдавать $\hat{y}$ очень близко к 0 или 1 , тогда как MSE с порогом $E_e=0.001$ останавливается при $|t-y|$ порядка $0.02-0.03$, и остаточная MAE в исходной шкале составляет ~ 0.33 (сигмоида асимптотически не достигает $0/1$). Однако разрыв невелик ($\approx 1.8\times$), поэтому в общем случае компромисс между удобством классификации (BCE) и прямым обучением на числах (MSE) сохраняется – он просто слабо проявляется на данной задаче с 4 точками.
4. **Устойчивость к случайной инициализации весов?** MSE – неустойчива: 1 из 5 запусков ($seed=3$) попал в локальный минимум с $E_s\approx 0.25$, ассигасу 0.50 и MAE 3.88 , порог не был достигнут за 10000 эпох. BCE – устойчива: все 5 запусков сошлись к $E_e=0.05$ с близким числом эпох (разброс всего $691-868$). Это подтверждает теоретическое преимущество BCE: его градиент не гаснет при насыщении выхода, поэтому траектория обучения меньше зависит от начальной инициализации и реже застревает в локальных минимумах.
5. **Подтвердилось ли наблюдение о линейной неразделимости XOR независимо от числовых меток?** Да, полностью: та же архитектура 2-2-1 со скрытым слоем успешно решает задачу для $c_0=-5/c_1=10$ (Вариант 14), как и для классического $0/1$ в ЛР №1. Линейная неразделимость определяется структурой данных XOR (пары (c_0,c_0) и (c_1,c_1) против (c_0,c_1) и (c_1,c_0)), а не конкретными значениями меток классов. Замена числовых меток не меняет топологию задачи, поэтому

однослойный персептрон по-прежнему не справится, а скрытый слой из 2 нейронов – справляется.

6. **Как выбор функции потерь соотносится с необходимостью скрытого слоя?** Ничего не влияет на этот вывод – он определяется исключительно архитектурой. И MSE, и BCE обучались на одной и той же сети 2-2-1 со скрытым слоем; функция потерь меняет лишь скорость и устойчивость сходимости, но не принципиальную возможность разделить линейно неразделимые данные – это обеспечивает только наличие скрытого слоя. Иными словами, выбор MSE vs BCE – это вопрос «как быстро и надёжно», а выбор «один слой vs два слоя» – вопрос «возможно ли вообще». Первый не подменяет второй.
7. **Что показывает визуализация разделяющей поверхности?** Граница между классами имеет форму, характерную для XOR: две диагональные полосы класса $s_0=-5$ (области, где A и B одновременно $\leq$ границы или одновременно $\geq$ границы) отделены от двух полос класса $s_1=10$ (области, где A и B лежат по разные стороны от границы). Это соответствует ожидаемой для XOR форме – пересечению двух полуплоскостей, формируемых скрытым слоем из 2 нейронов. По расположению границы MSE и BCE визуально почти совпадают (решается одна и та же задача одной архитектурой); различие – в «резкости» карты значений: у BCE переходы цвета контрастнее из-за более сильного насыщения выхода (логарифмический штраф выталкивает $\hat{y}$ к 0/1), у MSE – более плавный, размытый градиент.

Вывод: реализовал альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провёл сравнительный анализ обучения сети с MSE и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.