Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

По дисциплине: «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях: сравнение активационных функций»

Выполнил:
Студент 4 курса
Группы ИИ-25
Редькович С. В.
Проверила:
Андренко К. В.

Брест 2026

Цель работы: на основе многослойного персептрона архитектуры 2 – 2 – 1 из ЛР №2, исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Задание:

1. Взять за основу код многослойного персептрона 2 – 2 – 1 с функцией потерь BCE из ЛР №2.
2. Реализовать активационную функцию ReLU на скрытом слое и осуществить корректное обратное распространение ошибки для ReLU. На выходном слое оставить Сигмоиду.
3. Обучить сеть на полной таблице истинности в двух конфигурациях:
   - конфигурация A (базовая): MLP 2 – 2 – 1, Сигмоида на всех слоях, BCE, нормализованные целевые значения (0/1);
   - конфигурация B (новая): MLP 2 – 2 – 1, ReLU на скрытом слое, Сигмоида на выходном, BCE, нормализованные (0/1).
4. Критерий остановки для обеих конфигураций: суммарная ошибка $Es \leq Ee$ (как в ЛР №2).
5. Для каждой конфигурации зафиксировать:
   - количество эпох до критерия остановки;
   - итоговую суммарную ошибку и accuracy;
   - среднюю абсолютную ошибку в исходной шкале [c0; c1].
6. Провести не менее 5 запусков обучения для каждой конфигурации с разными seed и сравнить устойчивость.
7. Построить графики:
   - график сходимости (суммарная ошибка Es от эпохи) для обеих конфигураций на одних осях;
   - диаграмма разброса числа эпох по 5 запускам (столбики) для конфигурации A и B.
8. Визуализация разделяющей поверхности:
   - для представительного экземпляра каждой конфигурации построить карту (heatmap) выходного значения сети на плоскости $(A, B) \in [-10; 10]^2$ с наложением 4 точек обучающей выборки.
   - описать, как ReLU изменяет форму разделяющей поверхности (кусочно-линейные границы vs гладкие).
9. Реализовать режим функционирования сети:
   - пользователь вводит (A, B) из [−10; 10].
   - сеть выводит: выход в нормализованной шкале, выход в исходной шкале [c0; c1], класс.
   - продемонстрировать на 4 обучающих примерах + 2 – 3 дополнительных парах.
10. Создать таблицу сравнения (статистика по 5 запускам, MAE для обеих конфигураций).
11. Вывод: ответить на все вопросы и провести анализ результатов.

Требования к реализации:

- активационные функции: Сигмоида и ReLU;
- веса инициализируются случайными малыми значениями;
- обучение: метод обратного распространения в онлайн-режиме;
- критерий остановки: Es ≤ Ee или максимум эпох;
- допускается: NumPy, Matplotlib;
- запрещено: scikit-learn, PyTorch, TensorFlow и т.п.

Вариант 9 ($c0 = 3, c1 = -8$)

A	B	A ⊕ B
3	3	3
3	−8	−8
−8	3	−8
−8	−8	3

Ход работы:

1. Основа – код MLP 2-2-1 с BCE из ЛР№2

За основу взят код из ЛР2: архитектура 2 – 2 – 1, сигмоида на выходе, функция потерь BCE, нормализация целей (y-c0)/(c1-c0). Онлайн-обучение, критерий остановки Es ≤ Ee = 0.01 сохранены без изменений.

2. Реализация ReLU на скрытом слое и корректный backprop

Добавлена функция активации:

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \mathrm{ReLU}'(z) = \begin{cases} 1, & z > 0 \\ 0, & z \le 0 \end{cases}$$

Ключевой момент корректности: производная ReLU берётся от предактивации z (значения до применения функции активации), а не от уже активированного h = ReLU(z). Это принципиально: для сигмоиды производная выражается через сам выход (h(1-h)), а для ReLU – только через знак входа z (при h=0 не всегда понятно, был ли вход ровно 0 или отрицательным, если судить по h; по z – однозначно).

3. Обучение в двух конфигурациях

- **конфигурация A (базовая):** сигмоида на скрытом и выходном слоях, BCE, нормализованные цели (0/1);
- **конфигурация B (новая):** ReLU на скрытом слое, сигмоида на выходном, BCE, нормализованные цели (0/1).

4. Критерий остановки

Одинаков для обеих конфигураций: Es ≤ Ee = 0.01 (как в ЛР2), либо maxepoch = 5000.

5. Вопросы

1. Какая активация обеспечила более быструю/устойчивую сходимость?

По скорости – однозначно ReLU: когда сходится, делает это за ~290–300 эпох против ~2100–2250 у Sigmoid, то есть почти в 7 раз быстрее (отсутствие насыщения градиента на положительной полуоси ReLU даёт намного более сильный сигнал обучения). Но по устойчивости – наоборот, выигрывает Sigmoid: она сошлась во всех 5 запусках, а ReLU – только в 3 из 5, причём два незавершённых случая – это не медленная сходимость, а настоящий устойчивый тупик (проверено увеличением числа эпох в 10 раз – результат не изменился). Таким образом, у ReLU есть выигрыш по скорости ценой проигрыша по надёжности.

2. Как отличается форма разделяющей поверхности? Наблюдаются ли ожидаемые кусочно-линейные границы у ReLU?

Да, наблюдаются отчётливо: граница Sigmoid – гладкая, плавно изгибающаяся линия без изломов; граница ReLU – состоит из прямолинейных сегментов с заметными изломами в точках смены активных/неактивных нейронов. Это прямое следствие того, что ReLU кусочно-линейна, а сигмоида – гладкая нелинейная функция.

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

ReLU предпочитают, потому что на положительной полуоси её производная константна и равна 1 – градиент не затухает при прохождении через много слоёв (в отличие от сигмоиды, чья производная h(1-h) максимум 0.25 и быстро обнуляется при насыщении, что в глубоких сетях вызывает затухающий градиент). На нашей неглубокой сети (один скрытый слой) это преимущество в скорости действительно подтвердилось (291 эпоха против 2150), но у ReLU проявился и характерный для неё недостаток – умирающие нейроны, которых у сигмоиды в принципе не бывает (сигмоида никогда не выдаёт производную, равную нулю).

4. Изменилась ли способность сети решать XOR при переходе на ReLU?

Принципиально нет – обе конфигурации способны полностью решить задачу (accuracy=1.0) при удачной инициализации, поскольку архитектура с одним скрытым слоем из двух нейронов в обоих случаях формирует нелинейную границу, достаточную для XOR. Но на практике вероятность успеха ниже у ReLU: 3 успешных запуска из 5 против 5 из 5 у Sigmoid.

5. Есть ли случаи «мёртвых нейронов» при ReLU? Как это повлияло на обучение?

Да, зафиксирован явный случай: при seed = 5 один из двух скрытых нейронов выдаёт ноль на всех 4 обучающих примерах, то есть он «умер» на раннем этапе обучения (попал в область, где предактивация отрицательна для всех примеров выборки) и больше никогда не получает ненулевой градиент. В результате сеть фактически пытается решить XOR одним нейроном вместо двух, что невозможно – отсюда accuracy = 0.75 и застревание ошибки на ~2.09 даже после 50000 эпох. При seed = 1 классического мёртвого нейрона нет, но сеть всё равно попадает в похожий по сути тупик – неудачную конфигурацию, не позволяющую корректно разделить все 4 точки.

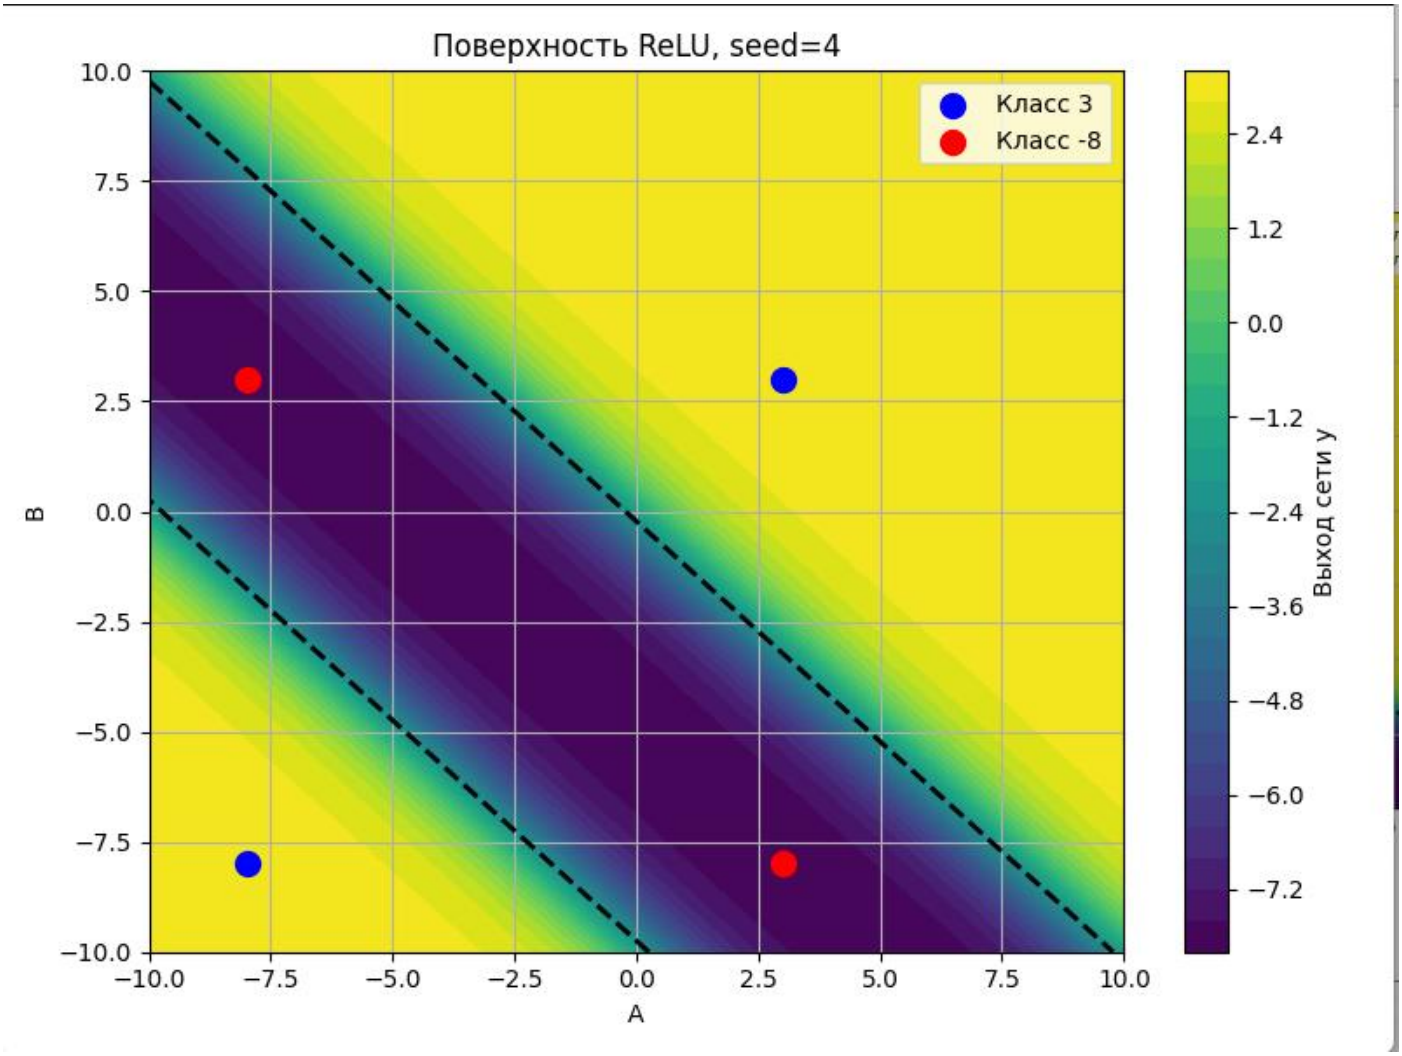
6. Как выбор активации соотносится с необходимостью многослойной архитектуры для XOR?

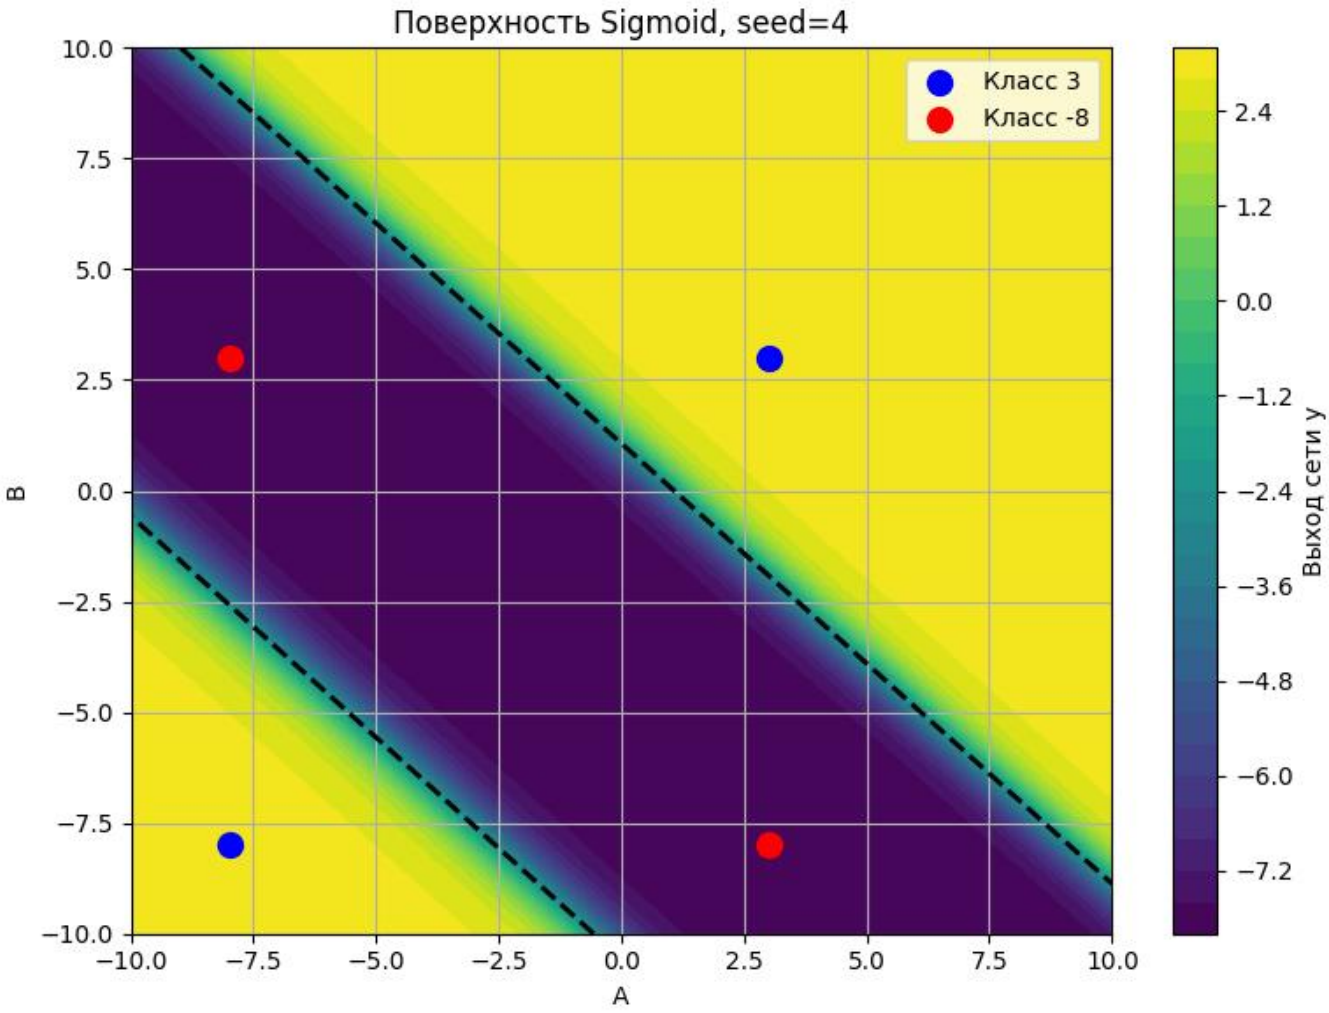
Никак не связан напрямую – необходимость скрытого слоя определяется линейной неразделимостью XOR и не зависит от того, какая активация на этом слое стоит. И Sigmoid, и ReLU на одном скрытом слое способны (при удачной инициализации) дать нелинейное разбиение плоскости, которого не может дать однослойный персептрон; разница активаций влияет только на скорость и устойчивость обучения, но не на принципиальную достижимость решения.

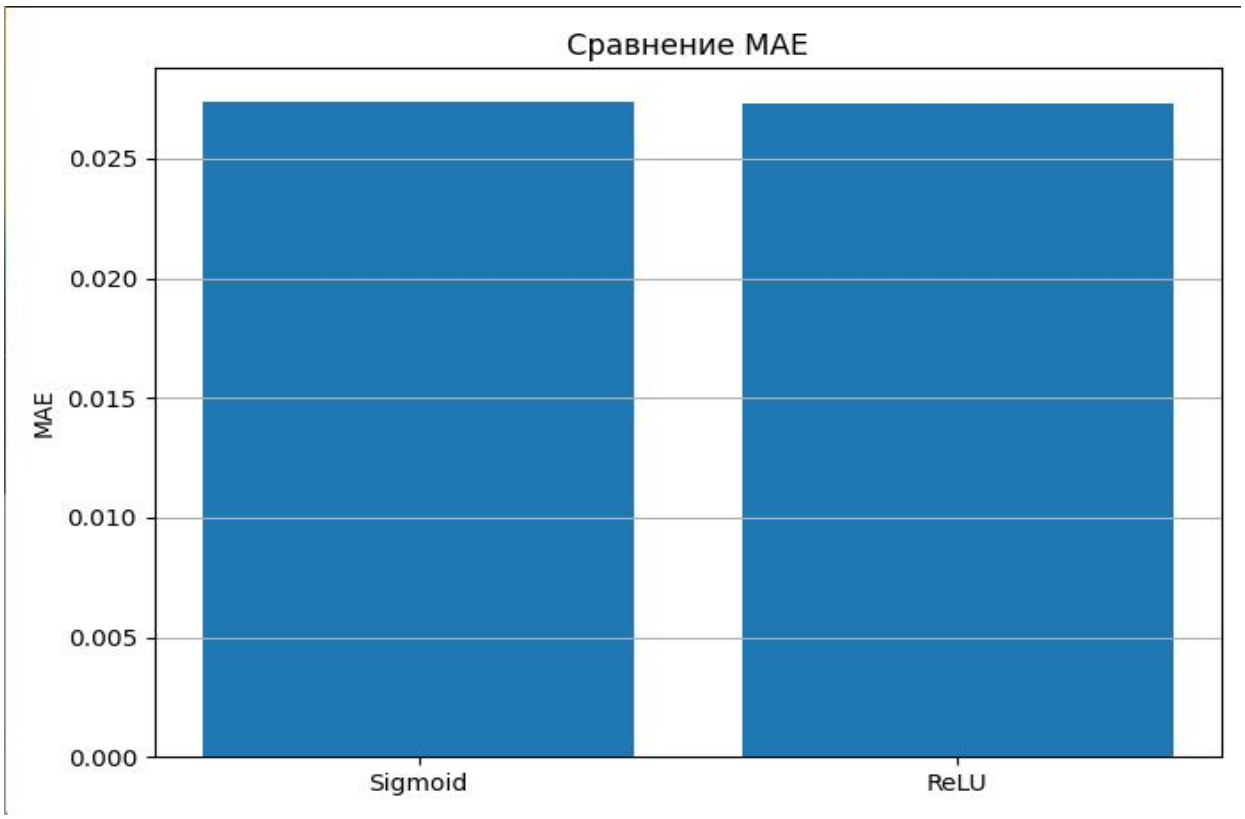
7. Что показывает визуализация для обеих конфигураций? Совпадает ли граница с ожидаемой для XOR?

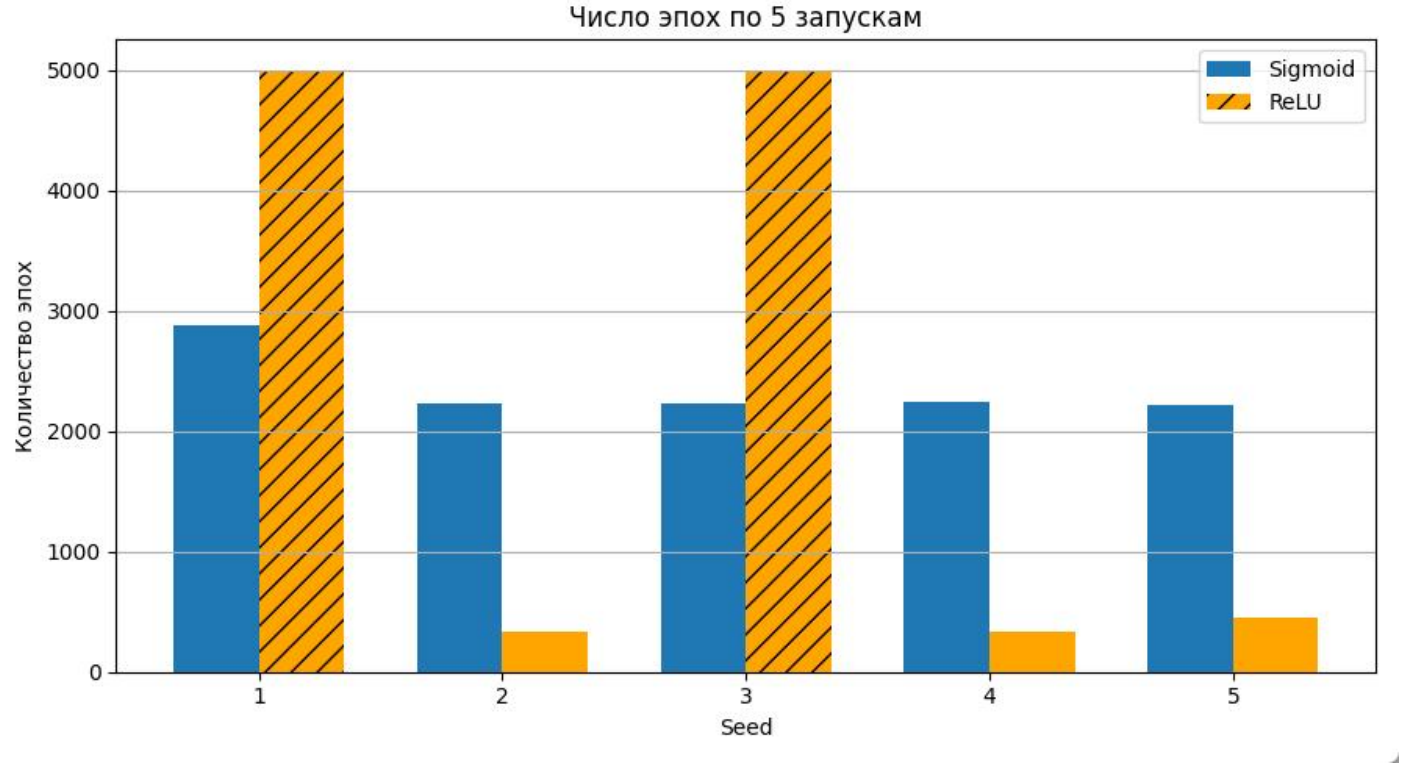
Для обеих конфигураций граница проходит двумя параллельными диагоналями, разделяющими пары (−9,−9)/(6,6) и (−9,6)/(6,−9) – это в точности ожидаемая для XOR форма (пересечение двух полуплоскостей, формируемых скрытым слоем), совпадающая с результатами ЛР2. Отличие – только в «гладкости» этой границы: у Sigmoid она плавная, у ReLU – кусочно-линейная с видимыми изломами.

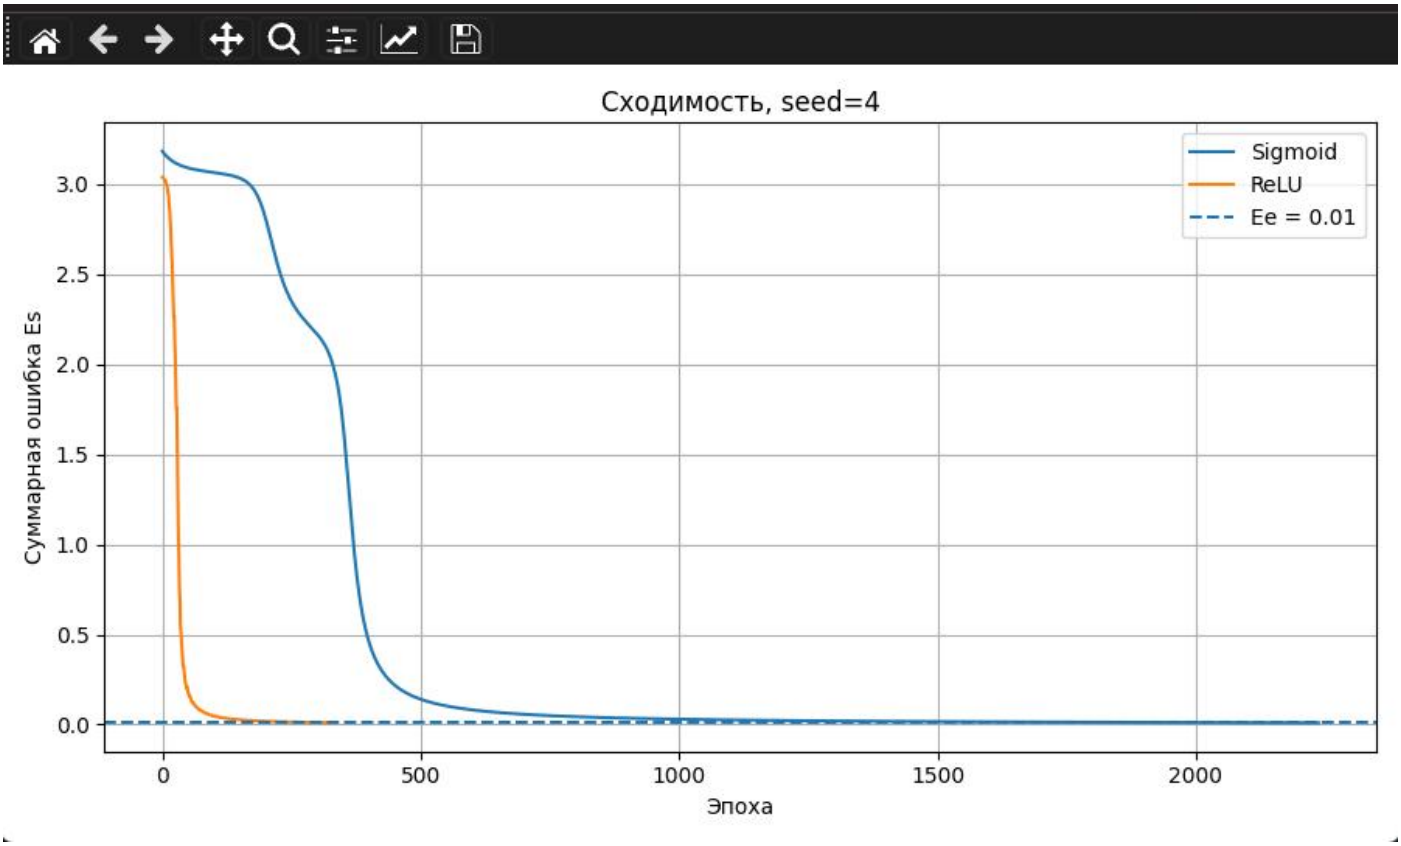
12. Результат работы программы




Поверхность Sigmoid, seed=4
Класс 3
Класс -8
A
B
Выход сети y
10.0
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
2.4
1.2
0.0
−1.2
−2.4
−3.6
−4.8
−6.0
−7.2


Сравнение MAE
MAE
0.025
0.020
0.015
0.010
0.005
0.000
Sigmoid
ReLU


Число эпох по 5 запускам
Sigmoid
ReLU
Количество эпох
Seed
0
1000
2000
3000
4000
5000
1
2
3
4
5


Сходимость, seed=4
Sigmoid
ReLU
Ee = 0.01
Суммарная ошибка Es
Эпоха
0.0
0.5
1.0
1.5
2.0
2.5
3.0
0
500
1000
1500
2000

```
  total_loss += float(-y_sample * np.log(p_clipped) - (1.0 - y_sample) * np.log(1.0 - p_clipped))
   1 |  2879 | 0.009995 |     1.00 | 0.0274
   2 |  2231 | 0.009998 |     1.00 | 0.0274
   3 |  2233 | 0.009995 |     1.00 | 0.0274
   4 |  2238 | 0.009995 |     1.00 | 0.0274
   5 |  2210 | 0.009997 |     1.00 | 0.0274

Конфигурация B: ReLU
Seed | Эпохи | Ошибка    | Accuracy | MAE
   1 |  5000 | 1.524101 |     0.75 | 2.7501
   2 |   329 | 0.009956 |     1.00 | 0.0272
   3 |  5000 | 1.524102 |     0.75 | 2.7501
   4 |   334 | 0.009981 |     1.00 | 0.0273
   5 |   456 | 0.009997 |     1.00 | 0.0272

Сравнение, seed=4
Метод    | Эпохи |   Ошибка | Accuracy |    MAE
Sigmoid  |  2238 | 0.009995 |     1.00 | 0.0274
ReLU     |   334 | 0.009981 |     1.00 | 0.0273

Предсказания Sigmoid
(   3,    3) -> norm=0.0022, y=  2.976, class=  3, expected=  3
(   3,   -8) -> norm=0.9978, y= -7.976, class= -8, expected= -8
(  -8,    3) -> norm=0.9978, y= -7.975, class= -8, expected= -8
(  -8,   -8) -> norm=0.0033, y=  2.963, class=  3, expected=  3
```

```
Предсказания ReLU
(   3,    3) -> norm=0.0008, y=  2.991, class=  3, expected=  3
(   3,   -8) -> norm=0.9958, y= -7.954, class= -8, expected= -8
(  -8,    3) -> norm=0.9958, y= -7.954, class= -8, expected= -8
(  -8,   -8) -> norm=0.0007, y=  2.992, class=  3, expected=  3

Таблица статистики
Seed | Sigmoid                          | ReLU
     | эпохи  ошибка  Acc   MAE        | эпохи  ошибка  Acc   MAE
   1 |  2879  0.0100  1.00  0.027      |  5000  1.5241  0.75  2.750
   2 |  2231  0.0100  1.00  0.027      |   329  0.0100  1.00  0.027
   3 |  2233  0.0100  1.00  0.027      |  5000  1.5241  0.75  2.750
   4 |  2238  0.0100  1.00  0.027      |   334  0.0100  1.00  0.027
   5 |  2210  0.0100  1.00  0.027      |   456  0.0100  1.00  0.027

Режим функционирования ReLU
Для выхода: letmeleavepls
A B [-10 10]:
Ошибка ввода. Пример: -3 7
A B [-10 10]: -3 7
Нормализованный выход: 0.0077
Выход в исходной шкале: 2.9155
Класс: 3
A B [-10 10]: -9 9
Нормализованный выход: 0.4348
Выход в исходной шкале: -1.7833
Класс: 3
```

Вывод: исследовал влияние активационной функции ReLU (Rectified Linear Unit). Провёл сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.