

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

По дисциплине: «Модели решения задач в интеллектуальных системах»
Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях: сравнение
активационных функций»

Выполнил:
Студент 4 курса
Группы ИИ-25
Заседатель Н.С.
Проверила:
Андренко К.В.

Цель работы: на основе многослойного персептрона архитектуры 2 – 2 – 1 из ЛР №2, исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Задание:

1. Взять за основу код многослойного персептрона 2 – 2 – 1 с функцией потерь BCE из ЛР №2.
2. Реализовать активационную функцию ReLU на скрытом слое и осуществить корректное обратное распространение ошибки для ReLU. На выходном слое оставить Сигмоиду.
3. Обучить сеть на полной таблице истинности в двух конфигурациях:
 - конфигурация А (базовая): MLP 2 – 2 – 1, Сигмоида на всех слоях, BCE, нормализованные целевые значения (0/1);
 - конфигурация В (новая): MLP 2 – 2 – 1, ReLU на скрытом слое, Сигмоида на выходном, BCE, нормализованные (0/1).
4. Критерий остановки для обеих конфигураций: суммарная ошибка $E_s \leq E_e$ (как в ЛР №2).
5. Для каждой конфигурации зафиксировать:
 - количество эпох до критерия остановки;
 - итоговую суммарную ошибку и ассигасу;
 - среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.
6. Провести не менее 5 запусков обучения для каждой конфигурации с разными seed и сравнить устойчивость.
7. Построить графики:
 - график сходимости (суммарная ошибка E_s от эпохи) для обеих конфигураций на одних осях;
 - диаграмма разброса числа эпох по 5 запускам (столбики) для конфигурации А и В.
8. Визуализация разделяющей поверхности:
 - для представительного экземпляра каждой конфигурации построить карту (heatmap) выходного значения сети на плоскости $(A, B) \in [-10; 10]^2$ с наложением 4 точек обучающей выборки.
 - описать, как ReLU изменяет форму разделяющей поверхности (кусочно-линейные границы vs гладкие).
9. Реализовать режим функционирования сети:
 - пользователь вводит (A, B) из $[-10; 10]$.
 - сеть выводит: выход в нормализованной шкале, выход в исходной шкале $[c_0; c_1]$, класс.
 - продемонстрировать на 4 обучающих примерах + 2 – 3 дополнительных парах.
10. Создать таблицу сравнения (статистика по 5 запускам, MAE для обеих конфигураций).
11. Вывод: ответить на все вопросы и провести анализ результатов.

Требования к реализации:

- активационные функции: Сигмоида и ReLU;
- веса инициализируются случайными малыми значениями;
- обучение: метод обратного распространения в онлайн-режиме;
- критерий остановки: $E_s \leq E_e$ или максимум эпох;
- допускается: NumPy, Matplotlib;
- запрещено: scikit-learn, PyTorch, TensorFlow и т.п.

Вариант 6 ($c_0 = -9$, $c_1 = 6$)

A	B	$A \oplus B$
-9	-9	-9
-9	6	6
6	-9	6
6	6	-9

Ход работы:

1. Основа – код MLP 2-2-1 с BCE из ЛР№2

За основу взят код из ЛР2: архитектура 2 – 2 – 1, сигмоида на выходе, функция потерь BCE, нормализация целей $(y - c_0)/(c_1 - c_0)$. Онлайн-обучение, критерий остановки $E_s \leq E_e = 0.01$ сохранены без изменений.

2. Реализация ReLU на скрытом слое и корректный backprop

Добавлена функция активации:

$$\text{ReLU}(z) = \max(0, z), \quad \text{ReLU}'(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

Ключевой момент корректности: производная ReLU берётся от преактивации z (значения до применения функции активации), а не от уже активированного $h = \text{ReLU}(z)$. Это принципиально: для сигмоиды производная выражается через сам выход ($h(1-h)$), а для ReLU – только через знак входа z (при $h=0$ не всегда понятно, был ли вход ровно 0 или отрицательным, если судить по h ; по z – однозначно).

3. Обучение в двух конфигурациях

- **конфигурация А (базовая):** сигмоида на скрытом и выходном слоях, BCE, нормализованные цели (0/1);
- **конфигурация В (новая):** ReLU на скрытом слое, сигмоида на выходном, BCE, нормализованные цели (0/1).

4. Критерий остановки

Одинаков для обеих конфигураций: $E_s \leq E_e = 0.01$ (как в ЛР2), либо $\text{maxepoch} = 5000$.

5 – 6. Результаты (5 запусков, разные seed)

Конфигурация А: Sigmoid

seed	эпох	ошибка	accuracy	MAE
1	2115	0.009996	1.00	0.0374
2	2148	0.009999	1.00	0.0374
3	2247	0.009995	1.00	0.0374
4	2150	0.010000	1.00	0.0374
5	2151	0.010000	1.00	0.0374

Сошлись все 5 запусков, разброс по эпохам небольшой (2115 – 2247).

Конфигурация В: ReLU

seed	эпох	ошибка	accuracy	MAE
1	5000(не сошлось)	1.524102	0.75	3.7502
2	290	0.009969	1.00	0.0372
3	300	0.009982	1.00	0.0372
4	291	0.009989	1.00	0.0372
5	5000(не сошлось)	2.089076	0.75	4.8581

ReLU сходится (seed 2,3,4) – это происходит на порядок быстрее Sigmoid (~290 эпох против ~2150), но в 2 из 5 запусков (seed 1, 5) сеть застревает и не достигает критерия остановки за 5000 эпох.

Диагностика причины (мёртвые нейроны). Проверил активации скрытого слоя на всех 4 обучающих примерах:

- seed = 5: один из двух нейронов скрытого слоя выдаёт строго 0 на всех 4 примерах – классический «мёртвый» ReLU-нейрон. Он ни разу не активировался ни на одном обучающем примере, поэтому градиент через него не течёт в принципе и веса, ведущие в него, больше никогда не обновляются. Фактически сеть вынуждена решать задачу XOR всего одним работающим нейроном вместо двух – а один нейрон не может сформировать нужную кусочно-линейную границу;
- seed = 1: оба нейрона технически «живы» (активируются хотя бы на одном примере), но сеть всё равно ошибается ровно на одном примере – (–9, 6) предсказывается как –2.0 вместо 6, что близко к границе между классами и неверно классифицируется. Это не классический dead ReLU, а неудачная конфигурация весов, устойчиво застрявшая в локальном минимуме с несовместимым расположением «изломов» ReLU относительно четырёх точек выборки.

Сравнение на одном seed=4 (для прямого сопоставления скорости):

	Sigmoid	ReLU
Эпохи	2150	291
Ошибка	0.010000	0.009989
Ассурасу	1.0	1.0
MAE	0.0374	0.0372

7. Графики

- сходимость (seed=4) – обе кривые на одних осях с линией $E_{\epsilon}=0.01$: ReLU «падает» к порогу практически вертикально уже к ~290-й эпохе, Sigmoid снижается заметно

дольше и плавнее (характерный S-образный спад к ~2000-й эпохе) – наглядная иллюстрация, почему ReLU в среднем быстрее, когда ей удаётся сойтись;

- диаграмма числа эпох по 5 seed – столбики Sigmoid стабильно около 2100 – 2250 без штриховки (все сошлись); столбики ReLU резко контрастные: три «карликовых» (~290–300 эпох, без штриховки) и два «упёршихся» в потолок 5000 со штриховкой (не сошлись) – визуально сразу видна нестабильность ReLU-конфигурации.

8. Визуализация разделяющей поверхности

Heatmap выходного значения сети на плоскости $(A,B) \in [-10;10]^2$ с линией границы классов и 4 точками выборки, для обеих конфигураций (seed = 4):

- Sigmoid: переход цвета между «жёлтой» и «тёмной» зонами плавный, граница – гладкая диагональная полоса без видимых изломов;
- ReLU: граница заметно более резкая, видны прямые отрезки и изломы (смена наклона полос) – прямое визуальное подтверждение кусочно-линейной природы ReLU: каждый скрытый нейрон вносит свой линейный «сгиб» в итоговую поверхность, и итоговая граница классов складывается из прямолинейных участков, а не из гладкой кривой.

9. Режим функционирования (модель ReLU, seed=4)

A	B	$\hat{y}_{\text{norm}}$	y (шкала [c0;c1])	Класс
-9	-9	0.0006	-8.991	-9
-9	6	0.9956	5.934	6
6	-9	0.9956	5.934	6
6	6	0.0006	-8.991	-9
5	5	0.0032	-8.951	-9
0	0	0.9459	5.188	6
1	-9	0.7593	2.389	6

Все 4 обучающих примера – верно. Дополнительные пары вне выборки: (5,5) уверенно относится к классу -9 (логично, оба значения положительные и близки, похоже на «6,6»-паттерн); (0,0) и (1,-9) модель относит к классу 6 – пограничный случай для (0,0): значение 5.19 не очень близко ни к одной из «якорных» точек выборки, что ожидаемо, т.к. точка (0,0) не похожа ни на один обучающий пример.

10. Сводная таблица (5 запусков)

seed	Sigmoid:эпохи	ошибка	Acc	MAE	ReLU:эпохи	ошибка	Acc	MAE
1	2115	0.0100	1.00	0.037	5000	1.5241	0.75	3.750
2	2148	0.0100	1.00	0.037	290	0.0100	1.00	0.037
3	2247	0.0100	1.00	0.037	300	0.0100	1.00	0.037
4	2150	0.0100	1.00	0.037	291	0.0100	1.00	0.037
5	2151	0.0100	1.00	0.037	5000	2.0891	0.75	4.858

11. Вопросы

1. Какая активация обеспечила более быструю/устойчивую сходимость?

По скорости – однозначно ReLU: когда сходится, делает это за ~290–300 эпох против ~2100–2250 у Sigmoid, то есть почти в 7 раз быстрее (отсутствие насыщения градиента на положительной полуоси ReLU даёт намного более сильный сигнал обучения). Но по

устойчивости – наоборот, выигрывает Sigmoid: она сошлась во всех 5 запусках, а ReLU – только в 3 из 5, причём два незавершённых случая – это не медленная сходимость, а настоящий устойчивый тупик (проверено увеличением числа эпох в 10 раз – результат не изменился). Таким образом, у ReLU есть выигрыш по скорости ценой проигрыша по надёжности.

2. Как отличается форма разделяющей поверхности? Наблюдаются ли ожидаемые кусочно-линейные границы у ReLU?

Да, наблюдаются отчётливо: граница Sigmoid – гладкая, плавно изгибающаяся линия без изломов; граница ReLU – состоит из прямолинейных сегментов с заметными изломами в точках смены активных/неактивных нейронов. Это прямое следствие того, что ReLU кусочно-линейна, а сигмоида – гладкая нелинейная функция.

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

ReLU предпочитают, потому что на положительной полуоси её производная константна и равна 1 – градиент не затухает при прохождении через много слоёв (в отличие от сигмоиды, чья производная $h(1-h)$ максимум 0.25 и быстро обнуляется при насыщении, что в глубоких сетях вызывает затухающий градиент). На нашей неглубокой сети (один скрытый слой) это преимущество в скорости действительно подтвердилось (291 эпоха против 2150), но у ReLU проявился и характерный для неё недостаток – умирающие нейроны, которых у сигмоиды в принципе не бывает (сигмоида никогда не выдаёт производную, равную нулю).

4. Изменилась ли способность сети решать XOR при переходе на ReLU?

Принципиально нет – обе конфигурации способны полностью решить задачу (ассигасу=1.0) при удачной инициализации, поскольку архитектура с одним скрытым слоем из двух нейронов в обоих случаях формирует нелинейную границу, достаточную для XOR. Но на практике вероятность успеха ниже у ReLU: 3 успешных запуска из 5 против 5 из 5 у Sigmoid.

5. Есть ли случаи «мёртвых нейронов» при ReLU? Как это повлияло на обучение?

Да, зафиксирован явный случай: при $\text{seed} = 5$ один из двух скрытых нейронов выдаёт ноль на всех 4 обучающих примерах, то есть он «умер» на раннем этапе обучения (попал в область, где преактивация отрицательна для всех примеров выборки) и больше никогда не получает ненулевой градиент. В результате сеть фактически пытается решить XOR одним нейроном вместо двух, что невозможно – отсюда ассигасу = 0.75 и застревание ошибки на ~ 2.09 даже после 50000 эпох. При $\text{seed} = 1$ классического мёртвого нейрона нет, но сеть всё равно попадает в похожий по сути тупик – неудачную конфигурацию, не позволяющую корректно разделить все 4 точки.



6. Как выбор активации соотносится с необходимостью многослойной архитектуры для XOR?



Никак не связан напрямую – необходимость скрытого слоя определяется линейной неразделимостью XOR и не зависит от того, какая активация на этом слое стоит. И Sigmoid, и ReLU на одном скрытом слое способны (при удачной инициализации) дать нелинейное разбиение плоскости, которого не может дать однослойный персептрон; разница активаций влияет только на скорость и устойчивость обучения, но не на принципиальную достижимость решения.

7. Что показывает визуализация для обеих конфигураций? Совпадает ли граница с ожидаемой для XOR?


Для обеих конфигураций граница проходит двумя параллельными диагоналями, разделяющими пары $(-9, -9)/(6, 6)$ и $(-9, 6)/(6, -9)$ – это в точности ожидаемая для XOR форма (пересечение двух полуплоскостей, формируемых скрытым слоем), совпадающая с результатами ЛР2. Отличие – только в «гладкости» этой границы: у Sigmoid она плавная, у ReLU – кусочно-линейная с видимыми изломами.

12. Результат работы программы





Сравнение MAE



Лабораторная работа 3
Вариант 6: $c_0 = -9$, $c_1 = 6$

Конфигурация A: Sigmoid

Seed	Эпохи	Ошибка	Accuracy	MAE
1	2115	0.009996	1.00	0.0374
2	2148	0.009999	1.00	0.0374
3	2247	0.009995	1.00	0.0374
4	2150	0.010000	1.00	0.0374
5	2151	0.010000	1.00	0.0374

Конфигурация B: ReLU

Seed	Эпохи	Ошибка	Accuracy	MAE
1	5000	1.524102	0.75	3.7502
2	290	0.009969	1.00	0.0372
3	300	0.009982	1.00	0.0372
4	291	0.009989	1.00	0.0372
5	5000	2.089076	0.75	4.8581

Сравнение, seed=4

Метод	Эпохи	Ошибка	Accuracy	MAE
Sigmoid	2150	0.010000	1.00	0.0374
ReLU	291	0.009989	1.00	0.0372

Предсказания Sigmoid

```
( -9, -9) -> norm=0.0022, y= -8.967, class= -9, expected= -9
( -9,  6) -> norm=0.9967, y=  5.950, class=  6, expected=  6
(  6, -9) -> norm=0.9978, y=  5.967, class=  6, expected=  6
(  6,  6) -> norm=0.0023, y= -8.966, class= -9, expected= -9
```

Предсказания ReLU

```
( -9, -9) -> norm=0.0006, y= -8.991, class= -9, expected= -9
( -9,  6) -> norm=0.9956, y=  5.934, class=  6, expected=  6
(  6, -9) -> norm=0.9956, y=  5.934, class=  6, expected=  6
(  6,  6) -> norm=0.0006, y= -8.991, class= -9, expected= -9
```

Таблица статистики

Seed	Sigmoid				ReLU			
	эпохи	ошибка	Acc	MAE	эпохи	ошибка	Acc	MAE
1	2115	0.0100	1.00	0.037	5000	1.5241	0.75	3.750
2	2148	0.0100	1.00	0.037	290	0.0100	1.00	0.037
3	2247	0.0100	1.00	0.037	300	0.0100	1.00	0.037
4	2150	0.0100	1.00	0.037	291	0.0100	1.00	0.037
5	2151	0.0100	1.00	0.037	5000	2.0891	0.75	4.858

Режим функционирования ReLU
Для выхода: letmeleavepls
A В [-10 10]: -9 -9
Нормализованный выход: 0.0006
Выход в исходной шкале: -8.9912
Класс: -9
A В [-10 10]: -9 6
Нормализованный выход: 0.9956
Выход в исходной шкале: 5.9343
Класс: 6
A В [-10 10]: 6 -9
Нормализованный выход: 0.9956
Выход в исходной шкале: 5.9343
Класс: 6
A В [-10 10]: 6 6
Нормализованный выход: 0.0006
Выход в исходной шкале: -8.9912
Класс: -9
A В [-10 10]: 0 0
Нормализованный выход: 0.9459
Выход в исходной шкале: 5.1883
Класс: 6
A В [-10 10]: 5 5
Нормализованный выход: 0.0032
Выход в исходной шкале: -8.9513
Класс: -9
A В [-10 10]: 1 -9
Нормализованный выход: 0.7593
Выход в исходной шкале: 2.3894
Класс: 6
A В [-10 10]: letmeleavepls

Вывод: исследовал влияние активационной функции ReLU (Rectified Linear Unit). Провёл сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.