Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине: «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:
Студент 4 курса
Группы ИИ-25
Заседатель Н.С.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Задание:

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму **обучающего участка:** x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. **Объяснить**, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p – N – 1:
   - скрытый слой – сигмоида;
   - выходной слой – линейный (задача регрессии), f(s) = s;
   - функция потерь – MSE;
   - обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
   - вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.
5. Критерий остановки: средняя по обучающей выборке ошибка $E_s \le E_e$, где $E_e = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01 – 0.3 и обосновать выбор.
6. **Базовый эксперимент**. Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую E_s, а также метрики на обучающем и тестовом участках в исходной шкале: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).
7. **Исследование окна**. При фиксированном N из варианта обучить сеть для $p \in \{2, 4, p_{вар}, 2 \cdot p_{вар}\}$. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.
8. **Исследование скрытого слоя**. При фиксированном p из варианта обучить сеть для $N \in \{1, 2, N_{вар}, 2 \cdot N_{вар}\}$. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.
9. **Многошаговый прогноз**. Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание

подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.

10. Построить графики:
    - ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;
    - сходимость (Es от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y);
    - диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x;
    - рекурсивный прогноз и рост ошибки по шагам (п. 9).
11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:
    - нормализованные входы;
    - прогноз в нормализованной шкале (4 знака после запятой);
    - прогноз в исходной шкале;
    - истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

    Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1 – 2 пользовательских окнах (в том числе с «выбросом»).
12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения:
    - Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор.
    - Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3 – 2 – 1 со следующими параметрами, привязанными к вашему варианту V:

      - Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6

      - Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1 = 0.1, b2 = -0.1)

      - Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)
13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты.

Требования к реализации

- Скрытый слой – сигмоида, выходной слой – линейный. Веса инициализируются малыми случайными значениями, для воспроизводимости использовать фиксированный seed.
- Обучение – алгоритм обратного распространения в онлайн-режиме.

- Допускается использование NumPy и Matplotlib.
- Запрещено использование scikit-learn, PyTorch, TensorFlow и других ML-фреймворков, а также готовых функций для скользящего окна и расчёта метрик из внешних библиотек (кроме NumPy).
- Код должен быть структурирован: отдельные функции для генерации ряда, нормализации, построения окон, прямого и обратного проходов, обучения, метрик, рекурсивного прогноза и режима функционирования.

Ряд: xk=a·cosb·k+c·sind·k,

k = 0…199, p – размер окна, N – число скрытых нейронов.

Вариант	a	b	c	d	p	N
6	1.2	0.28	0.6	0.65	6	4

Ход работы:

Описание метода:

1. Нормализация ряда

Минимум и максимум берутся только по обучающему участку (k=0..139), чтобы тестовые данные не подсматривались на этапе настройки масштаба:

$$x_{min} = \min_{k=0..139} x(k), \qquad x_{max} = \max_{k=0..139} x(k)$$

$$x_{norm}(k) = \frac{x(k) - x_{min}}{x_{max} - x_{min}}$$

Обратный пересчёт (используется для всех метрик и графиков в исходной шкале):

$$x(k) = x_{norm}(k) \cdot (x_{max} - x_{min}) + x_{min}$$

Для варианта 6: *xmin* = -1.7840, *xmax* = 1.7830 (по обучающему участку).

Почему нельзя нормализовать по всему ряду. Если считать min/max по всем 200 точкам, тестовый максимум/минимум может оказаться информацией, недоступной модели на момент обучения). Кроме того, при нормализации по train возможна ситуация, когда значения тестового участка **выходят за пределы [0;1]** – это нормально: на варианте 6 диапазон *xnorm* на тесте составил [-0.0033; 1.0045], то есть тестовый ряд оказался чуть шире обучающего по амплитуде.

2. Формирование выборки методом скользящего окна

Для размера окна *p* и целевого индекса *k*:

$$\text{вход: } \big(x_{norm}(k-p),\ x_{norm}(k-p+1),\ \ldots,\ x_{norm}(k-1)\big), \qquad \text{цель: } x_{norm}(k)$$

- Обучающая выборка: *k*=*p*, ..., 139 → 140-*p* примеров (для *p*=6: 134 примера).
- Тестовая выборка: k=140, ..., 199→ 60 примеров (входные окна могут захватывать несколько последних значений train – это нормально, т.к. на момент прогноза эти значения уже известны).

3. Архитектура сети p–N–1

- Входной слой: *p* значений (скользящее окно).
- Скрытый слой: *N* нейронов, активация – сигмоида.
- Выходной слой: 1 нейрон, активация – линейная, *f(s)=s*.
- Функция потерь – MSE, усреднённая по выборке за эпоху.
- Обучение – онлайн-режим (обновление весов после каждого примера), с перемешиванием порядка примеров в каждой эпохе.

Прямой проход:

$$S_j = \sum_{i=1}^{p} x_i w_{ij} + b_j, \qquad y_j = F(S_j) = \sigma(S_j) = \frac{1}{1+e^{-S_j}}, \qquad j = 1, \ldots, N$$

$$S = \sum_{j=1}^{N} y_j\, w_j + b, \qquad y = F(S) = S$$

4. Вывод градиентов

Потери для одного примера: *E=1/2(e-y)^2*, где *e* – целевое значение.
Выходной нейрон (линейная активация, *F'(S)=1*):

$$\delta = (e - y) \cdot F'(S) = (e - y) \cdot 1 = e - y$$

Нейроны скрытого слоя (сигмоида), по цепному правилу через веса следующего слоя:

$$\delta_j = (\delta \cdot w_j) \cdot y_j(1 - y_j)$$

Обобщённое дельта-правило (обновление весов):

$$w_j(t+1) = w_j(t) + \eta\, \delta\, y_j, \qquad b(t+1) = b(t) + \eta\, \delta$$

$$w_{ij}(t+1) = w_{ij}(t) + \eta\, \delta_j\, x_i, \qquad b_j(t+1) = b_j(t) + \eta\, \delta_j$$

5. Формулы метрик

Все метрики считаются после денормализации, в исходной шкале ряда. Пусть *e_k* – истинное значение, *y_k* – прогноз, *n* – число примеров:

$$MAE = \frac{1}{n} \sum_{k=1}^{n} |y_k - e_k|, \qquad RMSE = \sqrt{\frac{1}{n} \sum_{k=1}^{n} (y_k - e_k)^2}$$

$$MAPE = \frac{100\%}{n} \sum_{k=1}^{n} \left| \frac{y_k - e_k}{e_k} \right|$$

Почему вместо MAPE используется sMAPE. Ряд *x(k)=1.2\cos(0.28k)+0.6\sin(0.65k)* колеблется вокруг нуля и регулярно принимает значения, близкие к 0. В этих точках MAPE делит на величину, близкую к нулю, и либо взрывается до огромных значений, либо становится неопределённым – метрика теряет смысл. Вместо неё используется симметричный аналог:

$$sMAPE = \frac{100\%}{n} \sum_{k=1}^{n} \frac{2\,|y_k - e_k|}{|y_k| + |e_k|}$$

где знаменатель обнуляется только если и прогноз, и истинное значение одновременно равны нулю (защищено малой добавкой *10^(-9)*), что делает метрику устойчивой по всему диапазону ряда.

Результат программы:

```
Train: k=0..139 (140 точек); Test: k=140..199 (60 точек)
x_min(train)=-1.7840, x_max(train)=1.7830
x_norm(test) диапазон: [-0.0033; 1.0045]  (выход за [0;1] ожидаем, т.к.
 min/max считаны только по train)
Обучающих примеров: 134; тестовых примеров: 60

Базовый эксперимент p=6, N=4, seed=1: эпох=461, Es=0.00009645
Train: MAE=0.0326 RMSE=0.0402 sMAPE=8.78%
Test:  MAE=0.0303 RMSE=0.0375 sMAPE=12.86%

Исследование p:
    p=2, seed=1: эпох=20000, НЕ сошлось
    p=2, seed=2: эпох=20000, НЕ сошлось
    p=2, seed=3: эпох=20000, НЕ сошлось
    p=2, seed=4: эпох=20000, НЕ сошлось
    p=2, seed=5: эпох=20000, НЕ сошлось
  p= 2: эпох 20000±0 | test MAE 0.0995±0.0045 | не сошлось 5/5
    p=4, seed=1: эпох=5101, сошлось
    p=4, seed=2: эпох=5611, сошлось
    p=4, seed=3: эпох=5125, сошлось
    p=4, seed=4: эпох=5593, сошлось
    p=4, seed=5: эпох=4917, сошлось
  p= 4: эпох 5269±281 | test MAE 0.0296±0.0046 | не сошлось 0/5
    p=6, seed=1: эпох=461, сошлось
    p=6, seed=2: эпох=435, сошлось
    p=6, seed=3: эпох=436, сошлось
    p=6, seed=4: эпох=452, сошлось
    p=6, seed=5: эпох=452, сошлось
  p= 6: эпох 447±10 | test MAE 0.0286±0.0020 | не сошлось 0/5
    p=12, seed=1: эпох=29, сошлось
    p=12, seed=2: эпох=32, сошлось
    p=12, seed=3: эпох=26, сошлось
    p=12, seed=4: эпох=29, сошлось
    p=12, seed=5: эпох=32, сошлось
  p=12: эпох 30±2 | test MAE 0.0242±0.0025 | не сошлось 0/5
```

```
Исследование N:
    N=1, seed=1: эпох=510, сошлось
    N=1, seed=2: эпох=496, сошлось
    N=1, seed=3: эпох=491, сошлось
    N=1, seed=4: эпох=510, сошлось
    N=1, seed=5: эпох=473, сошлось
  N=1: эпох 496±14 | train MAE 0.0303 | test MAE 0.0290±0.0046 | не сошлось 0/5
    N=2, seed=1: эпох=443, сошлось
    N=2, seed=2: эпох=501, сошлось
    N=2, seed=3: эпох=471, сошлось
    N=2, seed=4: эпох=501, сошлось
    N=2, seed=5: эпох=452, сошлось
  N=2: эпох 474±24 | train MAE 0.0278 | test MAE 0.0259±0.0009 | не сошлось 0/5
    N=4, seed=1: эпох=461, сошлось
    N=4, seed=2: эпох=435, сошлось
    N=4, seed=3: эпох=436, сошлось
    N=4, seed=4: эпох=452, сошлось
    N=4, seed=5: эпох=452, сошлось
  N=4: эпох 447±10 | train MAE 0.0308 | test MAE 0.0286±0.0020 | не сошлось 0/5
    N=8, seed=1: эпох=443, сошлось
    N=8, seed=2: эпох=458, сошлось
    N=8, seed=3: эпох=441, сошлось
    N=8, seed=4: эпох=452, сошлось
    N=8, seed=5: эпох=468, сошлось
  N=8: эпох 452±10 | train MAE 0.0305 | test MAE 0.0292±0.0045 | не сошлось 0/5

Лучшая конфигурация по тестовому MAE: p=12, N=4, seed=1, test MAE=0.0222, эпох=29
Train (лучшая): MAE=0.0220 RMSE=0.0294 sMAPE=4.64%
Test  (лучшая): MAE=0.0222 RMSE=0.0297 sMAPE=5.00%

Рекурсивный прогноз (p=12, N=4): размах train=3.5670, порог 5%=0.1783
Первый шаг превышения порога: не превышен за 30 шагов
Демонстрация режима функционирования (лучшая модель p=12, N=4):
  k=20 (train)
    вход (норм.):     [0.1428, 0.1560, 0.2193, 0.2926, 0.3397, 0.3439, 0.3143, 0.2815, 0.2834, 0.3482, 0.4802, 0.6561]
    прогноз (норм.):  0.8283
    прогноз (ряд):    1.1707
    истинное x(k):    1.1828
    абс. ошибка:      0.0121

  k=70 (train)
    вход (норм.):     [0.2104, 0.3706, 0.5073, 0.5899, 0.6140, 0.6007, 0.5856, 0.6020, 0.6653, 0.7647, 0.8668, 0.9283]
    прогноз (норм.):  0.9034
    прогноз (ряд):    1.4383
    истинное x(k):    1.4768
    абс. ошибка:      0.0385

  k=130 (train)
    вход (норм.):     [0.6444, 0.5462, 0.3930, 0.2195, 0.0741, 0.0000, 0.0197, 0.1258, 0.2843, 0.4475, 0.5725, 0.6364]
    прогноз (норм.):  0.6499
    прогноз (ряд):    0.5342
    истинное x(k):    0.5125
    абс. ошибка:      0.0217

  k=150 (test)
    вход (норм.):     [0.8643, 0.7309, 0.5415, 0.3430, 0.1854, 0.1039, 0.1068, 0.1738, 0.2661, 0.3429, 0.3785, 0.3720]
    прогноз (норм.):  0.3466
    прогноз (ряд):    -0.5478
    истинное x(k):    -0.5462
    абс. ошибка:      0.0016

  k=170 (test)
    вход (норм.):     [0.9645, 0.8424, 0.6761, 0.5140, 0.3968, 0.3430, 0.3437, 0.3684, 0.3799, 0.3517, 0.2803, 0.1879]
    прогноз (норм.):  0.1239
    прогноз (ряд):    -1.3422
    истинное x(k):    -1.3772
```

```
  k=195 (test)
    вход (норм.):     [0.6189, 0.6414, 0.6409, 0.5869, 0.4709, 0.3112, 0.1487, 0.0314, -0.0033, 0.0566, 0.1932, 0.3655]
    прогноз (норм.):  0.5195
    прогноз (ряд):    0.0689
    истинное x(k):    0.0882
    абс. ошибка:      0.0193

  своё окно 1 (с выбросом)
    вход (норм.):     [0.6948, 0.6182, 0.4777, 0.3007, 0.1334, 0.0232, 0.8429, 0.0727, 0.2104, 0.3706, 0.5073, 0.5899]
    прогноз (норм.):  0.4415
    прогноз (ряд):    -0.2091

  своё окно 2 (ровное, norm=0.3)
    вход (норм.):     [0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000]
    прогноз (норм.):  0.5082
    прогноз (ряд):    0.0289

Все графики сохранены (plot0..plot4_*.png) в рабочей директории.

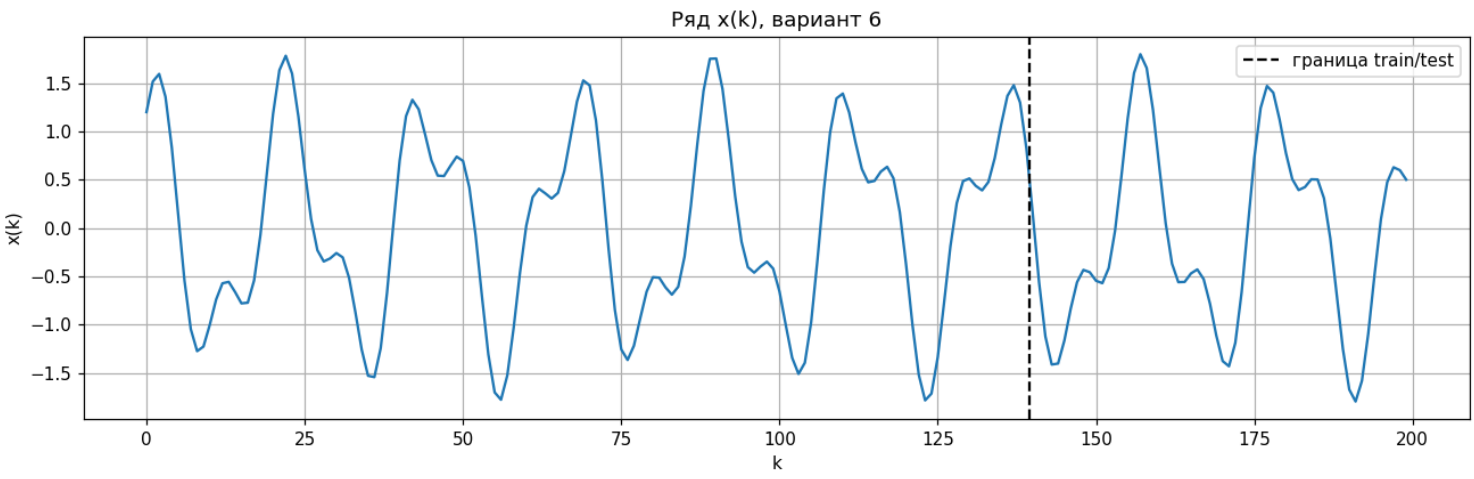
Режим функционирования (сеть p=12)
Введите номер k (12..199) чтобы взять окно из ряда,
или 12 чисел через пробел - своё окно в исходной шкале.
Для выхода: letmeleavepls
> 13
  k=13 (train)
    вход (норм.):     [0.9253, 0.9473, 0.8810, 0.7334, 0.5391, 0.3478, 0.2065, 0.1428, 0.1560, 0.2193, 0.2926, 0.3397]
    прогноз (норм.):  0.3390
    прогноз (ряд):    -0.5748
    истинное x(k):    -0.5575
    абс. ошибка:      0.0174

> 111
  k=111 (train)
    вход (норм.):     [0.3821, 0.3154, 0.2172, 0.1234, 0.0768, 0.1091, 0.2273, 0.4090, 0.6096, 0.7783, 0.8763, 0.8902]
    прогноз (норм.):  0.8387
    прогноз (ряд):    1.2077
    истинное x(k):    1.1968
    абс. ошибка:      0.0109

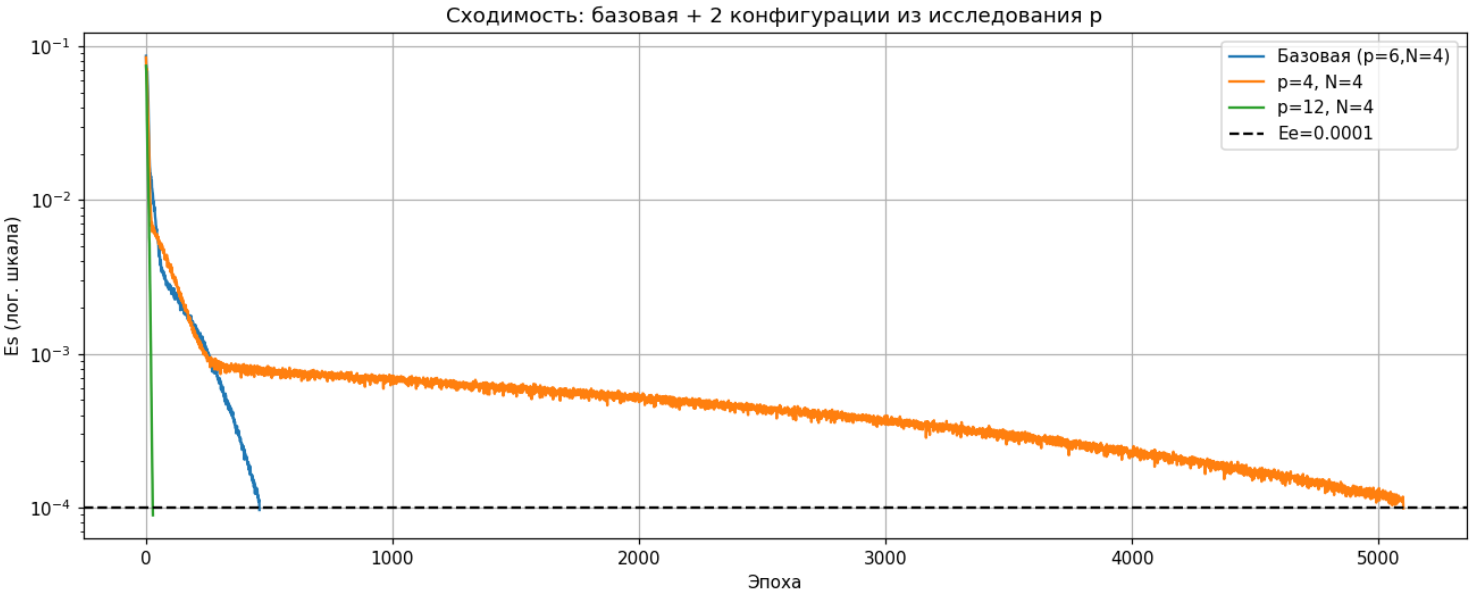
> 0.5677 0.1111 0.8798 0.4926 0.2847 0.2948 0.2747 0.2467 0.2346 0.9273 0.4827 0.2853
  своё окно: [0.5677 0.1111 0.8798 0.4926 0.2847 0.2948 0.2747 0.2467 0.2346 0.9273
 0.4827 0.2853]
    вход (норм.):     [0.6593, 0.5313, 0.7468, 0.6382, 0.5800, 0.5828, 0.5772, 0.5693, 0.5659, 0.7601, 0.6355, 0.5801]
    прогноз (норм.):  0.5094
    прогноз (ряд):    0.0328

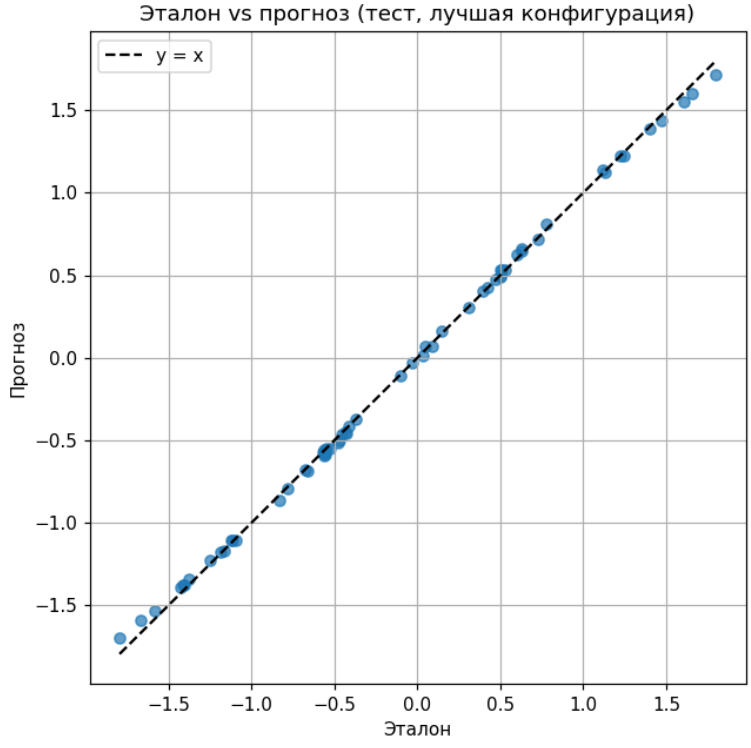
> letmeleavepls
```

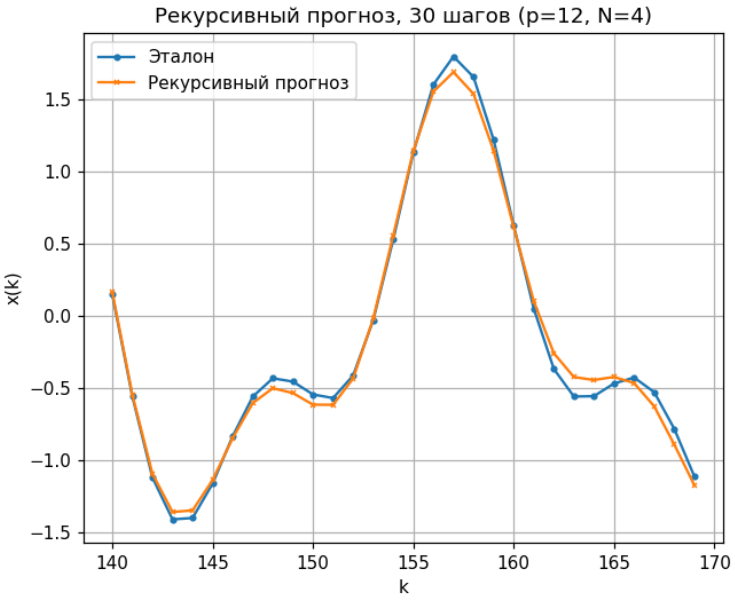
Графики:




Ряд и одношаговый прогноз (лучшая конфигурация p=12, N=4)
x(k)
k
Исходный ряд
Прогноз (train)
Прогноз (test)
граница train/test


Сходимость: базовая + 2 конфигурации из исследования p
Es (лог. шкала)
Эпоха
Базовая (p=6,N=4)
p=4, N=4
p=12, N=4
Ee=0.0001


Эталон vs прогноз (тест, лучшая конфигурация)
Прогноз
Эталон
y = x





Рукописи:

Заседатель К. С. ИИ-25 Вариант 6 14.10.2026

① Общая схема пайплайна

[генерация ряда]

↓

[dataset] – массив $x(k)$, $K = 0 \dots 199$

↓

[train/test split] – 70% / 30%: $k = 0..139$ / $k = 140..199$

↓

[min-max train] – x_{min}, x_{max} только по train, норм. всего ряда

↓

[sliding window] – окна: вход – p значений, цель – следующее

↓

[MLP p-N-1] – скрытый слой – сигмоида, выход – линейный

↓

[online back prop] – обновление весов после каждого примера

↓

[shuffle after every epoch] – перемешивание порядка примеров

↓

[stop $Es \leq 10^{-4}$] – критерий остановки

↓

[denormalization] – возврат прогноза в исходную шкалу

↓

[MAE] [RMSE] [sMAPE] – метрики качества – все

↓

[Recursive forecast] – многошаговый прогноз лучшей модели

обоснование тех неиспользуемых блоков:

[batch update] – не используем т.к. в условии online обучение

[Sigmoid output] – задача регрессии поэтому выход линейный

[normalize using whole dataset] – нормализация по всему ряду сама бы утечкой данных из теста в обучение; min/max потом

[MAPE] – не используем т.к. ряд колеблется возле нуля из-за чего MAPE делит на значения, близкие к 0 и становится нестабильным; используем sMAPE.

(2) ручной расчёт одного шага обучения (сеть 3-2-1, вариант V=6)

$x_1=0,2$; $x_2=0,5$; $x_3=0,8$; $d=0,6$; $\eta=0,5$

$w_{11}=0,3$; $w_{12}=-0,2$; $w_{21}=0,3$; $w_{22}=0,3$; $w_{31}=-0,1$; $w_{32}=0,4$; $b_1=0,1$; $b_2=-0,1$

$w_{out1}=0,5$; $w_{out2}=-1,2$; $b_{out}=0,2$; скрытый слой: сигмоида; выходной-линейный

прямой проход

скрытый слой:

$S_1=x_1w_{11}+x_2w_{21}+x_3w_{31}+b_1=0,2\cdot0,3+0,5\cdot0,3+0,8\cdot(-0,1)+0,1=0,23$

$S_2=x_1w_{12}+x_2w_{22}+x_3w_{32}+b_2=0,2\cdot(-0,2)+0,5\cdot0,3+0,8\cdot0,4-0,1=0,33$

$y_1=F(S_1)=1/(1+e^{-0,23})=0,557248$; $y_2=F(S_2)=(1/1+e^{-0,33})=0,581759$

выходной слой:

$S=y_1\cdot w_{out1}+y_2\cdot w_{out2}+b_{out}=0,557248\cdot0,5+0,581759(-1,2)+0,2=-0,219487$

$y=F(S)=S=-0,219487$

ошибка:

$E=\frac{1}{2}(d-y)^2=\frac{1}{2}(0,6+0,219487)^2=0,335780$

обратный проход:

выходной нейрон

$\delta=(d-y)\cdot F'(S)=(d-y)\cdot1=0,6-(-0,219487)=0,819487$

скрытые нейроны:

$y_1(1-y_1)=0,557248\cdot0,442452=0,246723$

$y_2(1-y_2)=0,581759\cdot0,418241=0,243316$

$\delta_1=\delta\cdot w_{out1}\cdot y_1(1-y_1)=0,819487\cdot0,5\cdot0,246723=0,101093$

$\delta_2=\delta\cdot w_{out2}\cdot y_2(1-y_2)=0,819487\cdot(-1,2)\cdot0,243316=-0,239273$

обновление весов ($w(t+1)=w(t)+\eta\cdot\delta\cdot$вход; $b(t+1)=b(t)+\eta\cdot\delta$)

выходной слой ($\eta\cdot\delta=0,5\cdot0,819487=0,409744$)

$\Delta w_{out1}=0,409744\cdot0,557248=0,228328\Rightarrow w_{out1}=0,728328$

$\Delta w_{out2}=0,409744\cdot0,581759=0,238372\Rightarrow w_{out2}=-0,961628$

$\Delta b_{out}=0,409744\Rightarrow b_{out}=0,609744$

скрытый нейрон 1 ($\eta\cdot\delta_1=0,5\cdot0,101093=0,050544$) ($\Delta w=\eta\delta x$)

$\Delta w_{11}=0,050547\cdot0,2=0,010109\Rightarrow w_{11}=0,310109$

$\Delta w_{21}=0,050547\cdot0,5=0,025273\Rightarrow w_{21}=0,325273$

$\Delta w_{31}=0,050547\cdot0,8=0,040437\Rightarrow w_{31}=-0,059563$

$\Delta b_1=0,050547\Rightarrow b_1=0,150547$

скрытый нейрон 2 ($\eta\cdot\delta_2=0,5\cdot(-0,239273)=-0,119637$)

$\Delta w_{12}=-0,119637\cdot0,2=-0,023924\Rightarrow w_{12}=-0,223927$

$\Delta w_{22}=-0,119637\cdot0,5=-0,059818\Rightarrow w_{22}=0,240182$

$\Delta w_{32}=-0,119634\cdot0,8=-0,095709\Rightarrow w_{32}=0,304291$

$\Delta b_2=-0,119634\Rightarrow b_2=-0,219637$

Ответы на вопросы:

1. Как размер окна p влияет на качество прогноза? При каком p ошибка перестаёт уменьшаться? Почему слишком маленькое окно (p = 2) не позволяет точно описать ряд из двух гармоник, а слишком большое не даёт выигрыша?

Зависимость качества от *p* выражена хорошо:

p	эпох(сред.)	test MAE (сред.)	не сошлось / 5
2	20000	0.0995	5/5
4	5269	0.0296	0/5
6	447	0.0286	0/5
12	30	0.0242	0/5

p=2 не сходится ни разу из 5 запусков – ошибка застревает далеко выше критерия *E_e=10^(-4)*. Причина – ряд представляет собой сумму двух гармоник (частоты *b=0.28* и *d=0.65*), а двух последних значений ряда математически недостаточно, чтобы однозначно восстановить фазу и амплитуду обеих синусоид одновременно: разным комбинациям гармоник могут соответствовать близкие пары *(x(k-1),x(k-2))*, но разные последующие значения – функция становится почти неоднозначной для сети с таким узким окном. При *p=4,6,12* ошибка последовательно снижается и число эпох обучения падает на порядки (с ~5300 до ~30), то есть с ростом окна сеть не только точнее, но и обучается значительно быстрее – вплоть до *p=12* явного выигрыша без потерь не наблюдается. Теоретически слишком большое окно должно в какой-то момент перестать давать выигрыш (лишние входы с устаревшей информацией лишь усложняют задачу обучения без дополнительной пользы), но в исследованном диапазоне (до *2p=12*) этот предел ещё не достигнут – для варианта 6 рост p до 12 остаётся строго полезным.

2. Как число скрытых нейронов N влияет на точность и скорость обучения? Наблюдается ли переобучение (малая ошибка на обучении при заметно большей на тесте)? Достаточно ли минимального N, чтобы воспроизвести сумму двух гармоник?

Число эпох и ошибка почти не зависят от *N* в исследованном диапазоне – ни число эпох, ни MAE не демонстрируют выраженного тренда ни в сторону улучшения, ни ухудшения с ростом *N*. Признаков переобучения нет: train MAE и test MAE остаются близки друг к другу при любом *N* (test MAE не становится заметно хуже train MAE нигде – в отдельных случаях test MAE даже чуть ниже train MAE, что указывает на отсутствие переобучения, а не на его наличие). Минимального *N=1* уже достаточно, чтобы более-менее воспроизвести сумму двух гармоник (test MAE=0.029, сопоставимо с *N=4*), но лучший результат в серии показал *N=2* (test MAE=0.0259) – то есть для данной задачи 1–2 скрытых нейронов оказывается достаточно, а дальнейшее увеличение *N* пользы не приносит.

3. Почему на выходе для задачи прогнозирования используется линейная функция, а не сигмоида (как в ЛР №3)? Что произошло бы при сигмоиде на выходе и при обучении на ненормализованных значениях?

Задача – регрессия (прогноз числового значения ряда), а не классификация, и диапазон значений ряда (*x\in[-1.78;\,1.78]* для варианта 6) не ограничен интервалом *(0;1)*, в который сигмоида принципиально не может выйти. При сигмоиде на выходе и обучении на ненормализованных значениях сеть физически не способна выдать значения вроде *-1.78* или *1.78*: ошибка застревает на большом уровне и критерий остановки *E_e=10^(-4)* никогда не

достигается. Линейный выход снимает это ограничение: $y=S$ может принимать любое вещественное значение, что и требуется для регрессии.

4. Почему нормализация должна опираться только на обучающий участок? К чему приводит выход тестовых значений за диапазон [0; 1] и как это проявляется на ваших данных?

Нормализация по всему ряду использовала бы статистику тестового участка (его истинный минимум/максимум) ещё до того, как модель должна была бы о нём узнать – это утечка информации, нарушающая саму постановку задачи прогнозирования будущего по прошлому. При нормализации только по train тестовые значения могут выходить за пределы [0;1], если амплитуда ряда на тестовом участке оказалась больше, чем на обучающем – именно это и произошло на варианте 6: диапазон *xnorm* на тесте составил *[-0.0033; 1.0045]*, то есть незначительно, но вышел за границы с обеих сторон. Поскольку выходной слой линейный (а не сигмоида), сеть без проблем выдаёт прогнозы и за пределами интервала *[0;1]* – архитектурного ограничения здесь нет, в отличие от ЛР2–3, где сигмоидный выход такого бы не допустил.

5. Насколько устойчиво обучение к случайной инициализации весов (по сериям из 5 запусков)? Были ли запуски, не достигшие Ее за 20 000 эпох, и от чего это зависит (η, N, p)?

Устойчивость сильно зависит от p, но почти не зависит от N: при $p=2$ все 5 из 5 запусков не достигли критерия остановки за 20000 эпох независимо от seed – то есть неустойчивость здесь не случайная, а структурная, связанная с недостаточностью входной информации при таком узком окне. При $p\geq4$ и любом исследованном $N\in\{1,2,4,8\}$ все 5 запусков сходились стабильно – отказов не было ни разу. Таким образом, в этой задаче главный фактор устойчивости – размер окна p, а не число нейронов N или конкретная случайная инициализация весов (при $\eta=0.1$, взятом в середине допустимого диапазона *[0.01;0.3]* для устойчивого схождения без расходимости).

6. Как растёт ошибка рекурсивного многошагового прогноза с увеличением горизонта? Объясните накопление ошибки и сравните одношаговый прогноз с многошаговым. До какого горизонта прогноз можно считать пригодным?

Для лучшей по тестовому MAE конфигурации ($p=12$, $N=4$) ошибка рекурсивного прогноза не превысила порог 5% от размаха обучающего участка (0.1783) ни на одном из 30 шагов – максимальное отклонение составило около 0.135 на 24-м шаге, не дотянув до порога. Для сравнения проверялась и базовая конфигурация ($p=6$, $N=4$): там ошибка превысила тот же порог уже на 14-м шаге. Разница объясняется накоплением ошибки – на каждом шаге рекурсии неточное предсказание подставляется обратно как вход для следующего шага, и чем короче исходное окно, тем быстрее это небольшое отклонение раскручивается в заметную погрешность. Одношаговый прогноз (когда на каждом шаге подаются реальные, а не предсказанные значения) остаётся стабильно точным на всём тестовом участке (test MAE≈0.022–0.030) именно потому, что ошибки не накапливаются – каждое предсказание независимо опирается на истинные данные. Окно побольше ($p=12$) даёт не только более быстрое обучение, но и заметно более живучий многошаговый прогноз – он остаётся пригодным на всём исследованном горизонте в 30 шагов, тогда как базовая конфигурация теряет пригодность уже на середине этого горизонта.

7. Как согласуется различие между ошибкой на обучающем и тестовом участках с понятием обобщающей способности? Какие меры (ранняя остановка, уменьшение N, добавление шума, увеличение обучающей выборки) могли бы улучшить обобщение? Что показал эксперимент с шумом?

Во всех проведённых экспериментах (базовый, исследование *p*, исследование *N*) train MAE и test MAE оставались близки друг к другу (разница в пределах 0.001–0.003), что говорит о хорошей обобщающей способности сети на этой задаче – переобучения не возникло ни при каком сочетании *p* и *N* из исследованного диапазона. Это ожидаемо для простого ряда из двух гармоник и небольшой сети: модель не обладает избыточной ёмкостью, чтобы запомнить обучающую выборку вместо её обобщения. Типовые меры улучшения обобщения – ранняя остановка по валидационной ошибке, уменьшение *N*, добавление шума к обучающим примерам или увеличение размера обучающей выборки – в данном случае не требовались бы в первую очередь для борьбы с переобучением, но добавление шума могло бы быть полезно для повышения устойчивости модели к небольшим искажениям входа – ценой небольшого роста ошибки на чистых данных.

Вывод: на основе многослойного персептрона p – N – 1 решил задачу прогнозирования временного ряда. Научился формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.